

基于监督学习的国标麻将 AI 优化

特征工程、网络结构与推理后处理

薛之瑶 2500012131

2026 年 6 月

Abstract

国标麻将（Chinese Standard Mahjong, CSM）是一个具有高度不确定性、部分可观测性和多智能体竞争特性的复杂棋牌游戏。本文系统总结了在 Botzone 平台上构建和优化 CSM 监督学习（Supervised Learning, SL）Bot 的完整过程。作者从仅 6 通道的基础特征出发，先扩展至 66 通道的单局牌面表示，再加入 4 个公开积分形势通道形成最终的 70 通道表示，引入基于残差网络（ResNet）的分头（multi-head）神经网络，并设计了结合危险度估计、向听数感知和特殊牌型检测的推理后处理框架。同时，作者探索了赢家数据过滤、番数加权采样等训练技巧，并在华为 Ascend NPU 上完成实际训练，解决了若干平台特有的数值稳定性问题。实验观察表明，特征扩展与规则后处理对 Bot 行为影响显著，并发现多个有趣现象——碰/杠行为消失、点炮率过高、胡牌番数偏低——本文分析了其根因并给出系统性解法。

1 引言

国标麻将是中国最流行的棋牌游戏之一，规则复杂性远超日本麻将：共 81 种番型、144 张牌、4 名玩家同场竞技，并存在吃、碰、杠等副露操作和最低 8 番的胡牌门槛。与完全信息博弈（如围棋）不同，麻将属于部分可观测马尔可夫决策过程（POMDP），传统搜索方法难以直接应用 [2]。

近年来强化学习（RL）和监督学习（SL）在麻将 AI 领域取得显著进展。Suphx [1] 在日本麻将上超越人类专业选手；IJCAI 2020 竞赛 [6] 为国标麻将提供了标准数据集与评测环境。本工作基于 IJCAI 2020 数据集，聚焦于 SL Bot 的系统性优化。

主要贡献

- 将观测通道数从 6 扩展至 66，再加入 4 个公开积分形势通道形成最终 70 通道表示；
- 设计基于 ResNet 的分头模型，引入动作类型辅助预测头；
- 提出向听数感知的危险度惩罚与现物奖励后处理框架；
- 引入七对/清一色专用特征通道与番数加权训练；
- 系统分析多个行为异常现象的根因，具有较强的工程参考价值。

2 背景与数据集

2.1 国标麻将规则摘要

国标麻将使用 144 张牌（万/条/筒各 1-9 各 4 张，外加字牌和花牌），4 名玩家轮流摸牌打牌。动作空间包括弃牌（34 种）、吃（63 种组合）、碰（34 种）、杠（明杠/暗杠/补杠各 34 种）、胡牌和过，共 235 个合法动作。胡牌需满足最低 8 番的门槛，鼓励玩家追求高番牌型。

2.2 数据集描述

训练数据来自 IJCAI 2020 冠军 Bot 的自对弈，共 98,209 局。参考实现为中科大团队（比赛第 4 名）的纯 SL 方案：状态空间 $4 \times 9 \times 145$ 通道，动作空间 235 维。

3 算法设计

3.1 观测特征工程

Table 1: 70 通道特征表示（最终版本）

通道区间	含义	数量
0	门风牌（one-hot 广播）	1
1	圈风牌（one-hot 广播）	1
2-5	手牌计数（第 k 层代表 $\geq k+1$ 张）	4
6-9	场上可见牌（弃牌 + 副露）	4
10-13	剩余牌数（归一化）	4
14	最近一张弃牌	1
15-18	各玩家牌墙剩余（归一化）	4
19-34	各玩家弃牌历史（ 4×4 ）	16
35-50	各玩家副露牌（ 4×4 ）	16
51	杠后摸牌标志	1
52	最后一张牌标志	1
53-55	对手危险度（3 位对手）	3
56-59	弃牌位置编码（归一化序号）	4
60	向听数（归一化，0=听牌）	1
61	有效进张牌（归一化剩余数）	1
62	七对向听数（归一化）	1
63-65	万/条/筒清一色向听数	3
66-69	公开分数与名次上下文	4
合计		70

特征矩阵维度为 $C \times 4 \times 9$ ($C = 70$)， 4×9 对应麻将牌的自然二维网格（4 种花色，每色 9 张）。

危险度估计（通道 53-55） 对每位对手 p 及候选弃牌 t ，采用启发式评分：

$$d(p, t) = \alpha_0 \mu[\text{非现物}] + \alpha_1 \mu[\text{筋牌}] + \alpha_2 \cdot \text{suit_pressure}(p) \quad (1)$$

其中现物（已被对手打出的牌）风险为 0，副露牌花色附近的牌风险更高（ α_2 随副露数线性增加）。

有效进张（通道 61） 穷举 34 种牌类测试向听数变化：若摸入牌 t 后向听数下降，则该格填入剩余张数 $\text{remaining}(t)/4$ ；否则为 0。最多调用 34 次 Mahjong-Shanten，在预处理阶段性能可接受。

特殊番型向听（通道 62-65） 七对向听 = $6 - |\text{对子数}|$ ；清一色向听粗估为 $13 - |\text{同花色手牌数}|$ ，归一化后分别写入对应通道。

公开分数与名次上下文（通道 66-69） 前 66 个通道能够描述单局内的牌面、进张与危险度，却无法区分“领先时保守”和“落后时追分”这两类牌面相同但目标不同的决策。为补充跨局积分赛中的策略条件，最终版本增加 4 个在决策时可观测的全局标量：自身分数、当前名次、与第一名的分差、以及相对最后一名的领先分差。四者分别按固定尺度归一化，并广播到 4×9 网格，从而与卷积主干兼容。若平台未提供局前公开分数，则四个通道保持为 0；预处理时也不读取牌局结束后的 Score 作为输入，以避免把未来结果泄漏给模型。因此，66 通道是仅依赖单局牌面信息的基础表示，70 通道则是在不引入隐藏信息的前提下加入积分形势的最终表示。

3.2 神经网络结构

网络采用 ResNet 风格的分头架构，如图 1 所示。

主干（Trunk） 两层卷积提取局面特征： $\text{Conv}_{3 \times 3}^{128} \rightarrow \text{BN} \rightarrow \text{ReLU} \rightarrow \text{Conv}_{3 \times 3}^{64} \rightarrow \text{BN} \rightarrow \text{ReLU}$ 。

残差块（ResBlock $\times 6$ ） 每块结构为： $\text{Conv}_{3 \times 3}^{64} \rightarrow \text{BN} \rightarrow \text{ReLU} \rightarrow \text{Conv}_{3 \times 3}^{64} \rightarrow \text{BN} \rightarrow \oplus \rightarrow \text{ReLU}$ ，其中 $\oplus$ 为残差加和，带 1×1 跳接投影层 [4]。

分头（Multi-Head） Flatten $\rightarrow \text{FC}_{512} \rightarrow \text{ReLU} \rightarrow \text{FC}_{256} \rightarrow \text{ReLU}$ 之后分叉：

- 动作类型头（type_head）：FC8，预测 8 类动作类型（Pass/Hu/Play/Chi/Peng/Gang/AnGang/BuGang）；
- 动作子头（6 个 tile_head）：每类动作各一个 FC，输出具体牌位 logit。

Logit 合成

$$\text{logit}(a) = \text{typeLogit}[\text{class}(a)] + \text{tileLogit}(a) \quad (2)$$

非法动作位填 -100.0 后做 softmax。选择 -100 而非 $-\infty$ 是为了避免与 label smoothing 交互时 $\log \text{softmax}(-\infty)$ 溢出。

训练目标

$$\mathcal{L} = \mathcal{L}_{\text{policy}} + 0.2 \mathcal{L}_{\text{type}} \quad (3)$$

$\mathcal{L}_{\text{policy}}$ 为番数加权交叉熵（见第 4 节）， $\mathcal{L}_{\text{type}}$ 为动作类型的交叉熵辅助损失。

3.3 推理后处理框架

推理时对模型原始 logit 依次施加以下调整（图 2）：

向听数感知危险惩罚

$$a_{\text{play}} -= 2.0 \cdot d(t) \cdot \min\left(1, \frac{\text{shanten}}{3}\right) \quad (4)$$

向听数 ≥ 3 时全力防守，向听数 = 0（听牌）时不惩罚，允许进攻摸胡。

现物（Genbutsu）奖励

$$a_{\text{play}} += 0.3 \quad \text{若 } t \in \bigcup_{p=1}^3 \text{discards}(p) \quad (5)$$

弱奖励（+0.3）确保模型有明显偏好时仍能覆盖规则建议，避免完全服从现物而放弃牌效。

听牌进攻 若 $\text{shanten} = 0$ ，则 $\text{Pass} -= 1.0$ ，抑制消极等待行为。

七对子保护 若七对向听 $\leq$ 普通向听且 ≤ 2 ，对子牌打出得 -0.5 惩罚，引导 Bot 保留对子追七对。

轻碰/杠惩罚 吃 -0.45 ，碰 -0.35 ，杠 -0.30 ，补杠 -0.25 ，平衡副露积极性（过强惩罚会导致碰/杠行为消失，见第 5 节）。

4 训练流程优化

4.1 赢家数据过滤

解析每局 Score 行，仅保留得分最高玩家的状态-动作对。直觉上胡牌玩家的决策更具参考价值；但完全过滤可能导致防守样本稀缺，是值得深入研究的权衡点。

4.2 番数加权采样

用赢家得分代理番数，计算样本权重：

$$w_i = \log_2 \left(\frac{\max(\text{score}_i, 8)}{8} \right) + 1 \quad (6)$$

8 分对应权重 1.0，128 分对应权重 4.0。加权策略损失为：

$$\mathcal{L}_{\text{policy}} = \frac{1}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} \bar{w}_i \cdot \text{CE}(f(s_i), a_i) \quad (7)$$

其中 $\bar{w}_i = w_i / \bar{w}$ 为 batch 内归一化权重。

4.3 延迟 LRU 加载

特征扩展后（6→70 通道），全量加载约需 30 GB 内存。改用 OrderedDict 实现 LRU 缓存（默认 256 个 .npz 文件），内存峰值降至 ~ 4 GB。

4.4 多进程预处理

使用 `multiprocessing.Pool.imap()` 并行处理，实测加速比约 $N_{\text{core}} - 1$ 倍。工程注意事项：连续特征须以 `float16` 保存（`int8` 会将 $[0, 1]$ 截断为 0）。

4.5 断点续训

保存完整训练状态（`model / optimizer / scheduler / epoch`），支持 `-resume` 从任意 checkpoint 继续，在云端 NPU 环境（任务超时频繁中断）中尤为重要。

4.6 最终版本训练结果

最终版本的训练日志记录了 16 个完整 epoch，每个 epoch 包含 769 个训练 mini-batch，共约 1.23×10^4 次参数更新。表 2 给出若干代表性轮次的固定验证集结果。

Table 2: 最终 SL 模型的验证集训练趋势

完成 epoch 数	验证损失	动作准确率
1	0.7286	75.13%
4	0.5134	81.46%
8	0.4031	84.83%
12	0.3598	86.46%
16	0.3455	87.02%

整体趋势可分为两个阶段。前 5 个 epoch 学习最快，验证准确率由 75.13% 提升至 82.54%，说明模型很快掌握了主要动作类型和常见弃牌模式；此后准确率继续稳定上升，但边际收益逐步减小，第 12–16 个 epoch 仅由 86.46% 提升至 87.02%。与此同时，验证损失从 0.7286 单调下降到 0.3455，最后几轮未出现损失回升或准确率下降，因而日志中没有明显的验证集过拟合迹象，而是进入了接近收敛的平台期。训练 mini-batch 的代表性记录也呈现一致趋势：策略损失由首轮开始时约 2.48 降至末轮约 0.27，动作类型损失由约 2.42 降至约 0.04–0.06，向听数与弃牌排序辅助损失也快速下降；胜负和番数辅助损失后期波动相对更大，反映终局结果比局部动作与向听状态更难预测。

需要强调的是，87.02% 表示在固定验证牌谱上复现专家动作的 top-1 分类准确率，并不等价于实战胡牌率或积分赛胜率。麻将中多个动作可能具有相近价值，因此离线准确率用于判断训练是否稳定收敛，而最终策略强度仍需结合 Botzone/IJCAI 对局结果评估。

5 有趣的现象与启发

5.1 碰/杠行为消失

现象：早期版本 Bot 完全不碰牌、不杠牌。

根因分析：两个耦合因素：赢家数据偏门清（清一色等番型往往门清不副露），导致训练集碰/杠样本极少；后处理惩罚过重（原始碰 -0.80 ，杠 -0.80 ），彻底掩盖模型的原始碰牌偏好。

解法：将惩罚降至碰 -0.35 、杠 -0.30 ，并对持有 3 张以上时额外回调奖励，恢复正常副露行为。

启发：后处理强规则与模型分布之间的耦合效应非常显著——过强的规则惩罚可能完全覆盖模型学到的有效策略，需在每次调参后进行行为层面的验证，而不仅仅是看 loss 或准确率。

5.2 频繁点炮问题

现象：Bot 以较高频率打出对手需要的胡牌牌（点炮）。

根因分析：纯 SL 模型从胡牌玩家视角学习，缺乏“哪张牌对手危险”的显式感知；PACK 通道虽已编码对手副露，但模型尚未建立可靠的危险度因果关联。

解法：引入危险度特征通道（通道 53–55）并结合式 (4) 的向听感知衰减——越接近听牌越少防守，实现进攻与防守的动态平衡。弱奖励安全牌（式 5， $+0.3$ ）比强惩罚危险牌更稳健，因为前者不会覆盖模型在牌效上的合理判断。

5.3 平均番数偏低

现象：Bot 胡牌平均番数较低，七对、清一色等高番牌型极少出现。

根因分析：高番局在训练数据中占比小（ $< 5\%$ ）；模型缺乏对七对、清一色等特殊番型向听进度的感知；未加权的交叉熵损失对低番高频样本过度拟合。

解法（已实现，重训后生效）：七对/清一色向听数特征通道（通道 62–65）+ 番数加权损失（式 7）+ 七对子后处理保护（ -0.5 惩罚打对子）。

5.4 NPU 平台数值稳定性问题

在华为 Ascend NPU 上训练时发现若干平台特有现象，对跨平台部署具有较强参考价值（表 3）。

Table 3: NPU 平台典型问题与解法

问题	现象	解法
<code>non_blocking = True</code>	error 507001 Segfault	NPU 强制关闭
<code>masked_fill</code>	loss 爆炸至 10^7	改用 -100.0
使用 <code>finfo.min</code>	归一化值截断为 0	改用 <code>float16</code>
<code>int8</code> 保存连续特征	log-softmax $(-\infty)$ 溢出	mask 值 ≥ -100

启发：跨硬件平台迁移时，数值稳定性问题往往比 API 兼容性更难调试；建议对关键张量的统计量（min/max/NaN 比例）进行实时监控。

6 开放式问题与研究方向

6.1 SL 上限与数据多样性

纯 SL 方法的上限受制于训练数据的策略分布。冠军 Bot 存在风格偏差（偏门清），使赢家过滤后副露样本稀缺。研究方向：多样化数据源混合（不同风格 Bot 的对局），或设计基于结果的重采样策略——在保留高质量赢家样本的同时，补充足够的防守样本以平衡策略分布。

6.2 从 SL 到 RL 的迁移

SL 模型是 RL 的良好初始化策略。参考 AlphaGo [2] 的经验, SL 策略网络 $\rightarrow$ RL 自博弈可进一步提升。挑战: CSM 的稀疏奖励 (仅局末才知道得分) + 4 人博弈的信用分配 + 番数计算的规则复杂性, 使奖励函数设计本身就是核心研究课题。

一个有趣的研究问题: 如何设计稠密中间奖励? 候选方案: 向听数变化奖励、危险度降低奖励、胡牌番数奖励。这些中间奖励是否会产生“奖励黑客”行为 (例如学会无限循环保持听牌状态)?

6.3 隐藏信息的贝叶斯推断

当前特征仅使用可见信息。对手手牌的贝叶斯推断是提升防守能力的重要方向:

$$P(\text{hand}_j | \text{obs}_{1:t}) \propto P(\text{obs}_{1:t} | \text{hand}_j) P(\text{hand}_j) \quad (8)$$

这本质上是基于不完整观测的手牌推断问题, 可用变分推断或粒子滤波建模, 是麻将 AI 区别于完全信息博弈的核心挑战。

6.4 后处理的参数化与可学习化

当前后处理系统包含约 10 个人工调参的超参数, 存在过拟合当前模型偏差的风险。研究方向: 用轻量残差网络替代规则后处理 (“可微规则”), 或通过少量对弈数据学习后处理层参数, 实现端到端优化。

6.5 番数预测辅助任务

可进一步引入番数预测头 (预测最终胡牌番数期望), 作为价值估计辅助信号, 为危险惩罚的衰减系数提供数据驱动的依据, 替代当前式 (4) 中的硬编码阈值 3。

7 结论

本文系统总结了国标麻将 SL Bot 从基础实现到工程化优化的完整过程, 主要贡献包括: 由 66 扩展到 70 通道的精细特征工程、ResNet 分头模型、向听数感知的推理后处理框架、赢家过滤与番数加权训练, 以及多项 Ascend NPU 工程适配。

实践表明, 特征工程与后处理规则对 SL Bot 行为的影响十分显著, 有时甚至超过模型容量本身。多个有趣的行为异常 (碰牌消失、频繁点炮、高番稀少) 都能追溯到数据分布偏差或后处理参数不当, 提示在 AI 棋牌游戏研究中需对数据质量和推理部署给予同等重视。

未来工作的主要方向是从 SL 过渡到 RL 自博弈, 引入隐藏信息推断模块, 以及将规则后处理参数化为可学习组件。

7.1 最终版本与代码评估补充

在多层实现和自对弈调参后, 当前代码已经不只是一个基础 SL 分类器, 而是一个包含特征工程、分解策略网络、辅助监督、推理后处理和可选 RL 微调框架的完整麻将 Bot。通道扩展遵循了从 “单局最优” 到 “积分赛最优” 的推理过程: 基础牌面编码先回答当前手牌如何更快成型, 危险度与番型通道再回答如何平衡进攻、

防守和做大牌, 由此形成 66 通道版本; 但实战积分赛表明, 同一牌面在领先、落后和末位追分时不应采用完全相同的风险偏好。因此最终版本只补入决策时确实可见的自身分数、名次、领先差和追赶差四个标量, 形成 $66 + 4 = 70$ 通道。选择这四项而不是四家原始局得分, 既给出了相对排名所需的充分上下文, 又避免维度冗余及终局信息泄漏。主要版本演进可以概括如下:

1. 基础 SL 版本: 使用 Botzone 日志构造动作分类数据, 按 235 维动作空间直接监督学习, 能完成合法动作选择, 但对向听数、防守风险和高番路线缺乏显式建模。
2. 特征增强版本: 将观测扩展到 66 通道, 加入手牌、副露、弃牌、剩余牌、牌墙、现物危险度、弃牌位置、向听数、有效牌、七对子和清一色/混一色路线等公开信息。
3. ResNet 分头版本: 使用残差卷积主干, 并把动作拆成动作类型头和具体牌/吃法子头, 缓解 235 维动作空间中不同动作类型样本不均衡的问题。
4. 训练数据优化版本: 加入赢家过滤、番数加权、Weighted Sampler、花色置换增强、延迟 LRU 数据缓存、多进程预处理和断点续训, 使模型更偏向学习高质量赢家样本。
5. 推理后处理版本: 在模型 logit 上叠加规则修正, 包括胡牌优先、听牌时降低 Pass、现物奖励、危险牌惩罚、七对子保对子、吃碰杠惩罚和后期危险牌折返门控。
6. 最终重训版本: 针对 66 通道无法表达积分形势的问题, 增加 4 个公开局势通道, 将输入扩展为 70 通道; 缺失分数信息时统一置零, 并禁止使用终局 Score 构造输入, 从设计上保证训练和比赛的信息边界一致。与此同时, 网络加入弃牌序列 GRU、风险头、番型路线头、胜率/番数/向听/弃牌排序辅助头; 训练目标改为条件式分层损失, 即动作类型、子动作和完整策略共同监督。

最终重训共完成 16 个 epoch 和约 1.23 万次 mini-batch 更新, 最佳 checkpoint 出现在最后一轮: 验证动作准确率为 87.02%, 验证损失为 0.3455。结合表 2 可以看出, 模型前期快速学习、后期平稳逼近平台, 且没有明显验证性能反弹; 因此最终提交采用第 16 轮权重。该指标衡量的是对专家动作的离线复现能力, 实战价值则由后处理和积分赛共同验证。

当前 SL 代码的功能分工如下。feature.py 负责把国标麻将局面编码为 70 通道张量, 同时只使用比赛时可见的信息; 4 个公开积分形势通道通过 set_public_scores 显式传入, 避免训练时使用上帝视角手牌造成信息泄漏。preprocess.py 将牌谱转为 npz 样本, 记录全局弃牌序列、赢家权重、风险标签和番型路线标签。dataset.py 提供懒加载缓存和花色置换增强。model.py 采用 ResNet+GRU 融合结构, 并输出分解动作 logit 与多任务辅助头。supervised.py 使用 AdamW、余弦退火、加权损失和辅助损失训练。__main__.py 则是 Botzone 交互入口, 在模型输出后做轻量的攻守平衡后处理。

7.2 RL 不如 SL 的原因

作为未纳入最终提交的探索方案,本项目曾在 SL checkpoint 基础上尝试 PPO 自博弈。其整体架构是带历史模型池的并行 Actor-Learner: 多个 Actor 在四人环境中采集轨迹, Actor-Critic 网络以 ResNet 为共享主干, 分别输出 235 维动作策略和标量局面价值; Learner 使用 GAE、PPO 截断目标、价值损失、熵正则及逐步衰减的 SL teacher KL 约束更新参数。奖励以终局得分为主, 并加入流局听牌/未听牌修正。该原型能够从 SL 策略 warm start, 但没有完整继承最终 SL 模型的 GRU 弃牌序列、风险头和番型路线等辅助模块。

结合文献综述可以看到, 强麻将 Bot 往往先依赖大规模、高质量牌谱做 SL, 再用非常长时间的自博弈微调。当前 RL 比不过 SL 的主要原因是训练预算和样本效率不匹配。国标麻将是四人不完全信息博弈, 奖励稀疏且延迟, 一次点炮、流局或自摸的得分要回溯到几十步之前的取舍, PPO 在这种场景下需要海量自博弈样本才能形成稳定改进。相比之下, SL 直接从强 Bot/赢家牌谱中学习, 起点已经包含大量有效先验。

其次, 当前 RL 的 reward shaping 只能粗略表达胡牌得分、流局听牌和未听牌惩罚, 难以精确描述“什么时候应该做大牌、什么时候应该收手防守”。如果 shaping 过强, 模型可能学到保听牌或盲目进攻等局部最优行为; 如果 shaping 过弱, 又会回到稀疏奖励导致学习极慢。多智能体自博弈还会带来非平稳性: 模型池中的对手不断变化, 旧采样数据与当前策略分布不完全一致, PPO ratio 和价值估计的方差都会上升。由于算力和时间限制, 本项目无法进行文献中顶尖系统那种数量级的长周期自博弈, 因此 RL 尚未充分超过 SL。

在实际对比中, 我们进行了多轮“一名 RL Bot 对阵三名 SL Bot”的四人博弈, RL 的对局胜率主要落在 20%-30% 区间。该范围围绕四个座位均势时的 25% 基准上下波动, 没有表现出稳定、显著的胜率提升; 不同 checkpoint 之间的波动也大于可确认的增益。这说

明在现有训练时长下, PPO 尚未可靠地把 SL 初始策略改进为更强策略。

最后, SL 最终版已经加入了很多对比赛有效的工程先验, 如风险估计、现物、防守门控、番型路线和弃牌序列; 而 RL 部分尚未完全复用这些结构。更合理的后续路线是: 先用当前 SL 作为强 teacher, 冻结一部分特征和序列编码器, 使用较小学习率和 KL 约束做长期微调; 同时把点炮惩罚、放銃对象、局面名次差和对手威胁度显式纳入 reward 与 value head。综合离线动作准确率、与三个 SL 对手的实战结果以及可用算力, 本项目最终选择训练更稳定、验证更充分的 SL 模型作为积分赛提交版本, 而将 RL 保留为后续需要更大规模自博弈预算的探索方向。

7.3 积分赛结果分析

最终 Bot 在课程比赛中取得第 9 名, IJCAI 积分赛中取得第 12 名, 说明该方案已经具备较强的实战竞争力。它的优势主要来自三个方面: 第一, 特征工程充分利用了国标麻将公开信息, 使模型不仅看见手牌, 还能感知牌墙进度、弃牌结构、向听进度和基本危险度; 第二, 分解动作头与辅助监督降低了动作空间学习难度, 提升了吃碰杠和打牌之间的校准能力; 第三, 推理后处理让模型在胡牌优先、听牌进攻、现物防守和大牌路线之间形成了可控折中。

不足也比较清晰。当前 Bot 仍然依赖人工调参的后处理, 面对强对手时点炮风险估计还不够细; 面对弱对手时有时不能充分扩大进攻收益, 面对强对手时又缺乏更精确的对手手牌概率推断。此外, 比赛中分数、名次差和局数阶段会影响策略, 但当前分数特征只是预留了可观测上下文, 尚未在大规模训练中充分学习。下一步最有价值的改进, 是使用更高质量和更多样的牌谱重训风险/番型辅助头, 加入真实名次差策略, 并在 SL teacher 约束下做长期 RL 微调。




Figure 1: 分头 ResNet 模型结构。主干提取局面特征, type_head 提供动作类型辅助监督, 6 个 tile sub-head 预测具体动作 logit, 最终合并后施加合法动作掩码输出 235 维策略向量。




Figure 2: 推理后处理流水线。每步对 logit 向量进行原地调整，最终取 argmax 输出合法动作。各步调整量均经过人工验证，确保模型偏好强时规则调整不覆盖模型判断。

References

- [1] Junjie Li, Shuai Ma, Malong Yang, Qiaoyuan Mo, Ning Ding, Qiang Yan, and Yuandong Tian. Suphx: Mastering mahjong with deep reinforcement learning. arXiv preprint arXiv:2003.13590, 2020.
- [2] David Silver, Aja Huang, Chris J. Maddison, Arthur Guez, Laurent Sifre, George van den Driessche, Julian Schrittwieser, Ioannis Antonoglou, Veda Panneershelvam, Marc Lanctot, Sander Dieleman, Dominik Grewe, John Nham, Nal Kalchbrenner, Ilya Sutskever, Timothy Lillicrap, Madeleine Leach, Koray Kavukcuoglu, Thore Graepel, and Demis Hassabis. Mastering the game of go with deep neural networks and tree search. Nature, 529(7587):484–489, 2016.
- [3] David Silver, Julian Schrittwieser, Karen Simonyan, Ioannis Antonoglou, Aja Huang, Arthur Guez, Thomas Hubert, Lucas Baker, Matthew Lai, Adrian Bolton, Yutian Chen, Timothy Lillicrap, Fan Hui, Laurent Sifre, George van den Driessche, Thore Graepel, and Demis Hassabis. Mastering the game of go without human knowledge. Nature, 550(7676):354–359, 2017.
- [4] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pages 770–778, 2016.
- [5] Matej Muračik, Martin Schmid, Neil Burch, Viliam Lisý, Dustin Morrill, Nolan Bard, Trevor Davis, Kevin Waugh, Marc Lanctot, and Michael Bowling. Deepstack: Expert-level artificial intelligence in heads-up no-limit poker. Science, 356(6337):508–513, 2017.
- [6] IJCAI-2020 Mahjong AI Competition. Botzone platform: Chinese standard mahjong. <http://www.botzone.org.cn/game/Chinese-Standard-Mahjong>, 2020.
- [7] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A. Rusu, Joel Veness, Marc G. Bellemare, Alex Graves, Martin Riedmiller, Andreas K. Fidjeland, Georg Ostrovski, Stig Petersen, Charles Beattie, Amir Sadik, Ioannis Antonoglou, Helen King, Dhharshan Kumaran, Daan Wierstra, Shane Legg, and Demis Hassabis. Human-level control through deep reinforcement learning. Nature, 518(7540):529–533, 2015.
- [8] Noam Brown and Tuomas Sandholm. Superhuman AI for multiplayer poker. Science, 365(6456):885–890, 2019.